

Tarea #3**TICS411 Minería de Datos***Profesores: Claudio Díaz – Sebastián Moreno - Eliana Vivas**Última actualización 27 de Abril de 2025***Clasificación de canciones k-pop**

La casa disquera UAI Music Group representa a una amplia variedad de artistas que producen canciones de distintos estilos musicales. En el contexto de su expansión hacia el mercado asiático, la disquera necesita clasificar si una canción nueva de su catálogo pertenece al género K-pop o no, con el fin de orientar correctamente la estrategia de venta, promoción y distribución al mercado asiático.

UAI Music Group le resulta cada vez más difícil realizar esta clasificación, ya que debe contratar a un experto en música el cual se demora semanas en distinguir si la canción es k-pop, lo cual resulta caro y pierden time-to-market.

Por esta razón, la disquera le ha solicitado su ayuda como Data Scientist. Usted ha recibido un conjunto de canciones, cada una con atributos como nivel de popularidad, energía, duración, tempo, características vocales, presencia de rap, entre otros. En este conjunto las canciones ya están clasificadas como k-pop y de otros géneros. Con base en estos datos, su tarea es crear un modelo de minería de datos que permita clasificar cada canción como “K-pop” o “No K-pop”.

Basándose en los contenidos abordados en clase, desarrolle los siguientes puntos:

Requerimientos del Código

El código debe ser escrito en **Python** utilizando **Jupyter Notebook** y debe cumplir con los siguientes pasos:

1. Carga de Datos

- Importar el archivo CSV (Datos.csv), localizado en WebCursos, que contiene la información de las canciones.
- Extraer únicamente las siguientes variables del conjunto de datos:
 - a) **Popularity** (popularidad de la canción): Toma valores de 0 a 100, donde 100 es muy popular.
 - b) **Danceability** (que tanailable es la canción): Toma valores de 0 a 1, donde 1 es muyailable.
 - c) **Speechiness** (cuanto se habla en la canción, como por ejemplo en un audio libro): Toma valores de 0 a 1, donde 1 es que se habla en toda la canción.
 - d) **Acousticness** (cuanto porcentaje de la canción es acústico): Toma valores de 0 a 1, donde 1 es muy acústico.
 - e) **Loudness** (que tan fuerte suena la canción, medido en decibeles): Tiene valores variables.
 - f) **Track Genre** (género de la canción): Toma valores 1 y 0, donde 1 es k-pop y 0 es no k-pop (otro género)

2. Limpieza de Datos

- Verificar que los datos seleccionados estén limpios (sin valores nulos, inconsistentes). Explicar la importancia de este proceso y detallar los datos que fueron limpiados.



- Aplicar al menos un algoritmo de detección de outliers (test de Grubbs, métodos de distancia, LOF, y/o isolation tree/forest) para la detección y evaluación de valores atípicos. Explicar la importancia de este proceso y detallar que se hizo con los valores atípicos.

3. Evaluación del modelo KNN con K=1, 10-fold cross validation, y min_max()

- Aplicar el algoritmo KNN para predecir la columna **Track Genre** utilizando 10-fold cross validation usando K=1 y *weights* = uniform. En el proceso de evaluación, cuando separe los folds de entrenamiento y test, aplique un proceso de normalización usando la función min_max() a las columnas seleccionadas.
- Atención, los parámetros usados para normalizar deben calcularse solo con el conjunto de entrenamiento, y luego aplicarse a ambos conjuntos, por lo cual este proceso se realiza 10 veces (ya que utilizará 10-fold cross validation).
- Justificar por qué es necesario normalizar los datos y explicar cómo se realizó este procedimiento.
- Indique que porcentaje de datos fueron bien clasificados (Accuracy), comparando las etiquetas predichas con las etiquetas reales. Analice el promedio y desviación estándar del accuracy y explique si este porcentaje es aceptable o no, y por qué.

4. Encontrar el Mejor K

- Volver a realizar el punto 3, pero esta vez usted elija el K. Debe elegir el mejor K en función de tres métricas de evaluación (Accuracy, Precisión y Recall) variando K entre 1 y 50. Gráfiquelas y argumente cuál es el mejor K.

5. Discusión: ¿normalización o estandarización?

- Volver al paso 3, y en vez de normalizar usando la función min max(), estandarice usando la función StandardScaler(). Realice luego todos los puntos del paso 3 y 4. Indique si el mejor K cambió y cuál de todos los modelos es mejor. Explique por qué sucede esto.

La entrega de la tarea se realizará en Jupyter Notebook, el cual debe incluir:

- Explicaciones detalladas de cada paso del código.
- Justificación de las decisiones tomadas en cada etapa del análisis.
- Comentarios claros dentro del código para facilitar su comprensión.
 - Si el código se entrega sin explicaciones, la calificación será **1.0**.
 - Si el código incluye explicaciones parciales, solo se evaluarán las partes explicadas.

Formato de Entrega

- En WebCursos, debe subir el código Python utilizado, en formato Jupyter Notebook (ipynb).
- La fecha de entrega es el día 31 de Mayo, 23:55hrs.
- En caso de entregar fuera de plazo, se descontará 10 décimas por hora (proporcional).

Disclaimer

Los datos originales provienen de Kaggle (el caso de estudio es ficticio basado en datos reales).

Ética

Si bien está permitido el uso de LLMs, en caso de sospecha de uso indiscriminado de LLM, se interrogará al grupo sobre el trabajo realizado. Si en esta interrogación algún integrante del grupo no pueda explicar el código, parcial o completamente, el grupo completo será calificado con nota 1.